2026 年度 CCF-蚂蚁科研基金（第二批次）申报课题介绍

一、 数据与人工智能方向

1. 面向大模型训练的合成数据训练前质量评估与校验方法研究
2. 面向企业的结构化数据基座模型关键技术研究
3. 面向用户反馈闭环的大模型研发实验自动化与自迭代关键技术研究
4. 面向可信医疗知识服务的医疗概念体系与关键技术研究
5. 面向垂域高可信的结构化符号推理知识表示与应用研究
6. 面向大模型基础设施的递归自优化与缺陷自修复技术研究
7. 多模态大模型投机解码效率提升研究
8. 面向智能体训练的真实环境虚拟化与规模化生成技术研究
9. 图像与视频 Token 化智能编码技术研究
10. 三维媒体感知与交互技术研究
11. 面向研发风险前置防控的代码图谱增强技术与自进化多智能体框架技术研究-子课题一（基于代码仓库精准分析技术的变更风险左移系统研发与应用）
12. 面向研发风险前置防控的代码图谱增强技术与自进化多智能体框架技术研究-子课题二（面向自进化的多角色智能体代码审计协作框架）

二、 超算与智算方向

1. 面向分布式训练、推理服务与 Agent 应用的低开销 Continuous Profiling 及其自进化机制研究
2. 面向 AI Agent 沙箱极速冷启动的 Nydus EROFS 按需加载与 Checkpoint/Restore 机制研究
3. 面向大模型强化学习后训练的 GPU 动态资源重分配技术研究
4. 面向大模型强化学习后训练的全局内存池化与高效数据传输技术研究

一、 数据与人工智能方向（支持金额不超过 30 万元）

1. 面向大模型训练的合成数据训练前质量评估与校验方法研究

研究背景

当前大模型训练日益依赖合成数据（包括合成轨迹、合成指令、合成推理链等）作为高质量数据供给的重要来源。然而，合成数据的质量评估面临一个根本性瓶颈：数据质量的验证严重依赖下游反馈。现有流程为：合成数据生产 → 数据清洗/过滤 → 消融实验（训练小模型验证）→ 评估模型效果 → 反推数据质量 → 迭代数据生产策略 → 再次合成 → 再次训练验证。该流程存在三个核心问题：

1) 反馈链路过长：从数据生产到获得质量结论需要经历完整的训练+评估循环，周期通常以天甚至周为单位，严重影响数据迭代效率；
2) 资源消耗巨大：每次数据质量验证都需要消耗大量 GPU 算力进行训练。当前团队服务于百灵、医疗大模型、金融大模型等多个模型方向，合成数据体量大，逐一训练验证的算力成本不可持续；
3) 信号滞后且间接：训练后评估得到的是一个聚合的"模型效果"信号，无法精确定位到"哪些数据好、哪些数据差、哪些数据有害"，只能给出整体数据的粗粒度判断；

团队希望突破这一瓶颈，建立训练前数据质量预测能力——在合成数据进入训练流程之前，就能对其质量、有效性和潜在风险进行量化评估，从而大幅缩短数据迭代周期、降低算力消耗、提升数据资产的投入产出比。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：完成合成数据整体与单条质量预测、低质量数据识别、轻量代理评估及多维质量特征提取的研究和设计，交付合成数据质量预测算法原型、包含多批次数据及对应训练后质量标注的基准数据集、特征提取工具集，并在百灵、医疗或金融大模型至少 1 个实际合成数据生产场景的质量检查与训练准入流程中完成原型落地
5) 技术指标：

a. 质量评估算力成本不高于完整训练与评估流程的 10%，无需对每批待评估数据进行完整模型训练即可获得质量估计；
b. 在独立测试批次上，预测质量分数与训练后模型性能增益的 Spearman 等级相关系数不低于 0.70，能近似反映合成数据的训练价值；
c. 自动化特征提取覆盖不少于 7 个质量维度，包括正确性、多样性、复杂度、新颖性、一致性、信息密度、任务相关性，支持单条与批次数据；

d. 在经人工复核或可验证规则标注的测试集上，低质量数据识别的 F1 值不低于 0.80，有效识别内容错误、逻辑矛盾、任务偏离等问题，为训练准入提供依据。

返回首页

2. 面向企业的结构化数据基座模型关键技术研究

研究背景

用户增长、搜索推荐、广告营销、数字金融和风险控制等业务场景包含大量基于结构化数据的分类、回归、排序、时间序列预测、聚类与异常检测任务。当前主要采用“一场景一模型”的建设方式，每个新任务都需要重新进行数据处理、特征工程、模型选型、训练调参和效果验证，研发周期长、人工成本高，并造成数据规律、特征能力和模型知识难以跨场景复用。在冷启动、小样本、标签稀缺及业务快速变化的场景下，传统建模方式的局限更加明显。

基础模型通过大规模预训练形成通用能力，并以少量样本或轻量化微调快速适配下游任务，已推动自然语言和计算机视觉领域的技术范式变革。但结构化数据具有字段语义异构、数据类型多样、表间关系复杂、数据分布差异大等特点，尚缺乏能够统一适配多种业务数据与建模任务的通用基础模型。

本课题拟研究面向多场景、多任务的结构化数据基础模型，通过统一数据表示、跨数据集预训练和高效任务适配，学习可迁移、可复用的结构化数据通用能力，支持分类、回归、时序、聚类和异常检测等多类任务，为新业务场景快速构建高质量强基线。研究成果有望推动结构化数据建模从“一场景一模型”向“一套预训练模型适配多类任务”转变，缩短模型研发周期，降低建模成本，提升小样本和冷启动场景下的模型效果，为企业规模化、标准化和智能化的数据建模提供技术基础。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：完成面向长上下文、高 QPS 及时序预测的结构化数据模型架构算法设计，交付一套支持分类、回归、聚类及时序预测的算法原型，以及适用于 GI 用户增长和搜推广场景的统一评测验证框架，并提供可运行源代码、训练与推理配置、接口文档、模型权重及相关 checkpoint
5) 技术指标：研究基于双轴长上下文建模、表格—时序统一表征与高效推理的方法，提升分类准确率、回归及时序预测精度和聚类效果，产出模型、在线推理服务和统一评测体系。具体指标如下：

a. 在相同硬件、Batch Size 及上下文条件下，单卡 QPS 提升不少于 50%，单位推理成本降低不少于 20%；
b. 模型综合性能达到主流专用模型强基线的 95%以上，其中不少于 60%的测试数据集达到或超过强基线；
c. 在仅使用目标任务 10%标注样本的条件下，模型性能达到全量数据专用模型的 85%以

上；在未参与预训练的新数据集上，经轻量化适配后，相比同规模模型从头训练，核心性能指标平均提升不低于 5%

返回首页

3. 面向用户反馈闭环的大模型研发实验自动化与自迭代关键技术研究

研究背景

大模型进入真实业务后，用户纠错、重复提问、结果采纳、任务完成情况及专家复核意见持续产生，但这些反馈往往稀疏、有噪声，且与模型版本、数据、提示词、检索结果和执行轨迹分散存储。研发团队难以判断问题的真实原因，也难以将典型失败转化为可复现的评测样本和可验证的改进实验。离线评测结果与用户实际体验可能不一致，而完整训练实验成本高、周期长，进一步制约了迭代效率。

本课题拟研究以真实用户反馈为起点的大模型研发实验自动化方法，构建“反馈采集与校准—失败诊断—实验假设生成—成本感知的分级验证—线上效果检验—经验沉淀”的闭环。由人设定业务目标、实验预算与上线约束，智能体辅助完成问题发现、实验设计与执行、结果分析和下一轮建议，使用户反馈持续转化为可验证的研发决策。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：

a. 形成一套用户反馈与研发轨迹关联机制。 建立反馈、会话/任务、模型与配置版本、检索和工具调用轨迹、评测结果的统一表示；对反馈进行去噪、分层抽样和专家校准，形成可追溯的问题样本池；

b. 在至少一个蚂蚁真实研发场景中验证，例如医疗大模型后训练、数据配比优化、Agent-Skills 自进化或 MoE 实验迭代。

5) 技术指标：

a. 对照现有人工研发流程，重点衡量“反馈出现至形成可复现评测和实验结论”的周期，争取从周级缩短到天级；在相同实验预算和预先定义的有效性门槛下，使无效实验占比相对下降 20%—30%；

b. 由研发专家独立复核自动分析报告与下一轮建议，目标是建议采纳率达到 30% 以上；同时以预先指定的线上用户指标和时延、成本约束验证实际收益，避免仅凭离线评分宣布改进。

返回首页

4. 面向可信医疗知识服务的医疗概念体系与关键技术研究

研究背景

可信医疗知识服务正从通用问答走向“依据充分、结论可解释、过程可追溯”的新阶段，其基础在于统一、可扩展的医疗概念体系。当前医疗知识分散于标准术语体系、临床指南、药品说明书、医学文献、临床试验及业务数据中，存在概念标准不统一、别名缩写复杂、跨源映射困难、证据粒度不一致等问题，导致疾病、药品、检查、治疗、证据等核心对象难以一致表达与稳定复用。现有 RAG 方法主要基于文本切片与语义召回，面对复杂医疗问题时易出现实体混淆、证据覆盖不足、多跳推理能力弱和来源冲突不可控等问题，难以支撑高可信医疗知识服务。本课题围绕“医疗概念体系”这一核心底座，研究实体标化与链指、知识增强检索、复杂问题自动研究、冲突检测与解决等关键技术，形成支撑可信医疗知识服务的一体化方法体系。

本课题围绕可信医疗知识服务需求，重点开展四方面研究：

（1）医疗概念体系构建：基于 OMOP 等标准，构建覆盖疾病、药品、检查、治疗、指南、文献和证据对象的统一概念体系与语义框架；

（2）实体标化与跨源链指：研究面向中文医疗场景的实体识别、标准化、消歧和多源对齐技术，提升知识统一表达能力；

（3）知识增强检索与复杂问题自动研究：研究面向复杂医疗问题的概念扩展、混合召回、领域 reranker、多跳检索与自动研究机制，提升复杂问题求解能力；

（4）冲突检测与解决：构建证据组织与冲突裁决方法，提升结论可信性与可解释性。

实施上采用“概念体系建设—核心算法研发—原型系统集成—场景评测验证”的技术路线，形成可落地的关键技术方案与原型系统。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类或蚂蚁认可的期刊/会议论文至少 2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：完成面向可信医疗知识服务的医疗概念体系构建关键技术的算法设计，交付一套适用于医疗知识组织与服务场景的医疗概念体系构建原型系统，包括概念建模、术语归一、实体标化与消歧、跨源链指、知识增强检索、证据组织与冲突检测等核心模块，以及相关源代码、模型权重、配置文件、训练与推理 checkpoint
5) 技术指标：研究基于医疗概念体系与知识增强检索推理的方法，提升医疗实体标准化、复杂问题证据召回与回答可信性，形成面向可信医疗知识服务的关键技术方案。在开源数据集上，实体标准化/链指准确率提升 8%以上，复杂医疗问题 Top-10 证据召回率提升 10%以上；在蚂蚁和/或其关联公司场景落地，与现有算法相比，复杂医疗问题回答正确率提升 10%以上，多跳问题平均推理时延缩短 15%以上

返回首页

5. 面向垂域高可信的结构化符号推理知识表示与应用研究

研究背景

Verifier 通用知识服务：大模型在医疗、金融等严肃场景面临幻觉问题，本课题从逻辑推理知识表示与应用出发，探索一阶谓词逻辑+知识图谱的符号表示与符号推理引擎双系统架构，使 AI 输出从"大概率正确"走向"逻辑可证明正确"；交付符号规则自动抽取、推理校验引擎、LLM→符号校验→违规回溯闭环三项核心能力，对标"基于医疗知识底座建设 AI 原生核验 Verify 解决方案"，支撑诊断诊疗场景 Verifier 准确率达>90%、召回率>70%、吞吐量 10 万/天。

可信的医疗知识底座：WKG OKR 核心定位是"提供 AI 可直接消费的可信、可校验、可持续演进的高质量知识供给"，本项目结合符号推理引擎与知识 Verifier 自反馈 Loop 机制，支撑将医学权威文献形式化为逻辑约束，构建可推理、可验证、可证伪的医疗主张库与逻辑库，支撑跨源一致性计算与知识动态演化闭环，目标提供知识表示层突破；通过符号推理的自然归因能力——当模型违反某条规则时精确指出违反的具体逻辑约束及来源——形成"Verify 检测→归因分析→知识修正→知识再验证"的知识飞轮，驱动医疗知识库持续演进。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利不少于 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：完成结构化符号推理知识的表示方法知识表示设计，一套集成知识自动构建、逻辑规则质检和符号推理引擎的端到端框架，及其源代码与文档
5) 技术指标：探寻适用于医疗诊断、金融合规等高逻辑约束场景的神经符号融合推理范式，助力医疗诊断诊疗场景 Verifier 服务的落地，研究基于形式逻辑与知识图谱融合的符号推理知识表示方法，提升严肃场景问答的逻辑一致性准确率，形成一套面向垂直领域的结构化符号推理知识构建、质检与推理框架。在开源评测数据集上，逻辑一致性达到 sota 效果；在蚂蚁相关业务场景落地，先比原有算法框架，错误校验召回率提升 10%以上，准确率提升 5%以上，吞吐提升 2 倍以上

返回首页

6. 面向大模型基础设施的递归自优化与缺陷自修复技术研究

研究背景

随着大模型架构、训练规模及推理系统复杂度持续增长，大模型基础设施的性能优化、正确性保障与故障治理面临日益复杂的系统性挑战。模型、训练框架、编译器、运行时、通信网络及硬件之间高度耦合，问题定位与优化往往需要跨越多个技术层次，依赖少数领域专家的知识与经验。当前，从系统观测、问题诊断、优化方案生成，到代码修改、实验验证和生产发布，仍存在链路长、人工介入多、试错成本高、历史经验难以复用等问题。传统依赖人工分析、固定规则和静态自动化脚本的工程方式，难以适应模型架构与基础设施的快速演进，逐渐成为制约模型迭代效率和基础设施规模化发展的关键瓶颈。近年来，大模型在代码理解、复杂推理、工具调用和长链路任务执行方面的能力不断提升，为 AI 深度参与基础设施研发与运维提供了新的技术可能。然而，现有 Agent 技术仍主要聚焦单次任务执行，缺乏对复杂系统的深度理解、可靠的实验验证机制，以及跨任务积累和复用工程经验的能力，尚难形成持续自我改进的工程闭环。

本课题拟研究面向大模型基础设施的 RSI（Recursive Self-Improvement）关键技术，构建“系统观测—问题诊断—方案生成—自动实验—效果验证—安全执行—经验学习”的自主优化闭环，使 AI 能够深入模型训练与推理系统，持续提升基础设施的性能、正确性与稳定性。课题重点探索性能自优化、精度自对齐、缺陷自修复三类核心能力，并研究支持跨任务经验积累、自适应策略优化和持续能力演进的 Self-Evolving Agent Harness，形成可验证、可复用、可持续改进的智能工程技术体系。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 系统原型：研发一套面向大模型基础设施的递归自优化与自修复原型系统，支持系统观测、智能诊断、方案生成、自动实验、效果验证及经验学习等核心功能；实现性能自优化、正确性自对齐和缺陷自修复的典型应用，交付算法设计、源代码、测试用例及相关技术文档
5) 技术指标：

a. 基础设施自主优化与修复能力，覆盖性能自优化、精度与正确性自对齐、缺陷自修复三类典型场景，完成不少于 3 类真实工程任务的自动化闭环验证，实现问题发现、根因诊断、方案生成、自动实验及效果验证，并在约定测试集上验证性能收益、正确性保障及故障修复效果。

b. 自主闭环能力，在受控测试环境中，实现至少 2 类工程任务从诊断、修改、验证到结果反馈的端到端自主执行，支持验证失败后的自动回退与重新探索，减少人工介入。

c. 递归自改进能力，建立基于历史任务轨迹、经验记忆及 Tool/Skill 演化的持续改进机制，

通过对照实验验证任务成功率、人工介入次数及任务解决成本的改善，并评估在未见任务上的泛化能力。

返回首页

7. 多模态大模型投机解码效率提升研究

研究背景

目前大模型推理工程中，为了提升解码效率，使用小尺寸的草稿模型推理，主模型做验证接受已经成为主流方式，比如随着主模型一起训练产出的 MTP，近期 DS 开源的 Dspark，都是极大提高了纯文本推理的效率，降低了成本。但是相比纯文本接受长度可以到 8 以上的情况，多模态接受长度长期徘徊在 1.x~ 2.x 的范围，急需从算法加工程协同改善。以提升百灵多模态模型推理效率，为阿福、金融等重点场景提供百灵落地支撑。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：完成新的或者改进的草稿模型的算法设计，交付一套基于蚂蚁百灵多模态基模草稿模型的训练框架，及其源代码、权重等 checkpoint
5) 技术指标：研究新的活着改进方法，提升接受长度 3.x 以上，接受率平均超过 75%以上或者对齐相同条件下纯文本接受率和长度

返回首页

8. 面向智能体训练的真实环境虚拟化与规模化生成技术研究

研究背景

随着大模型从对话与推理能力向自主规划、工具调用和复杂任务执行演进，Agentic RL正成为提升智能体能力的重要技术路径。与传统基于静态数据的模型训练不同，Agentic RL需要模型与环境持续交互，通过执行任务、观察状态变化和获取反馈实现策略优化。因此，高质量、可规模化的交互环境正成为制约智能体训练效率与能力提升的关键基础设施。真实业务环境广泛涉及网页、应用、API、代码仓库、操作系统以及复杂的用户与系统状态。直接使用真实环境进行训练，面临环境构建成本高、并发能力受限、状态难以复现、外部依赖不稳定以及数据安全风险等挑战，难以支撑大规模强化学习和持续模型迭代。现有环境构建方式主要依赖人工开发、规则模拟或预先录制的交互轨迹，在环境保真度、任务多样性、状态覆盖率和自动化生成能力方面仍存在明显不足。尤其是如何保持虚拟环境与真实环境的行为一致性，如何生成具有有效学习价值的任务，以及如何验证虚拟环境训练效果能够迁移至真实环境，仍是需要重点突破的研究问题。

本课题拟研究从真实环境到可执行虚拟环境的自动化转换技术，将真实系统的界面、接口、状态、行为约束及任务流程抽象为可复现、可控制、可验证的环境模型；进一步研究环境规模化生成、并行执行、任务难度自适应演化及环境生命周期管理，形成从真实环境采集、虚拟环境构建到训练反馈驱动环境演化的完整技术体系。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 系统原型：研发一套面向 Agentic RL 的真实环境虚拟化与规模化生成原型系统，包含环境自动建模、虚拟环境生成、状态重置与回放、任务验证、环境演化及并行执行等核心模块，交付完整源代码、算法模型及必要的训练权重、测试用例和技术文档
5) 技术指标：

a. 环境自动生成能力，支持不少于 3 类典型 Agent 交互环境，完成不少于 100 个可执行虚拟环境或环境变体的自动化构建。
b. 环境保真度：建立真实与虚拟环境的一致性评测基准，在约定测试集上，关键状态转移及任务结果的一致率达到 90% 以上。
c. 环境演化能力：实现基于模型能力评测及失败轨迹的任务自动生成和难度自适应调整。

返回首页

9. 图像与视频 Token 化智能编码技术研究（备注：本课题支持金额不超过 50 万元）

研究背景

随着移动互联网普及，全球视觉数据量激增，视频流量占比超 80%。然而，传统编码标准（如 H.266/VVC）依赖手工模块且以像素失真为优化目标，在极低码率下易产生块效应，且缺乏语义建模，难以直接服务于分类、生成等下游智能任务。在大模型时代，视觉压缩亟需同时满足极高压缩率、丰富语义保留及面向智能任务的直接可用性三重需求。

在此背景下，"Token 化”成为连接压缩与理解的关键范式，推动编码从“面向人眼”向“面向智能”演进。当前研究呈现三大趋势：一是利用一维 Latent Token 捕获全局语义，实现重建与生成的统一；二是突破传统运动补偿，通过时空掩码与记忆机制实现视频高效压缩；三是构建统一离散 Token 空间，使云端大模型无需像素重建即可直接消费压缩数据，催生“压缩 - 理解 - 生成”一体化新范式。

尽管进展显著，现有研究仍面临三大瓶颈：首先，图像与视频 Token 化缺乏统一框架，模态间难以共享表示空间；其次，Token 语义丰富度与压缩效率的权衡尚未系统探索，极低码率下语义保持能力不稳定；最后，面向大模型的自适应编码策略不成熟，无法根据任务动态筛选关键 Token 子集。

针对上述问题，本项目旨在构建统一的图像与视频 Token 化智能编码框架。核心目标包括：第一，设计基于一维隐 Token 的紧凑表示与率 - 失真 - 语义联合优化机制，在极低码率（视频<0.02bpp，图像<0.05bpp）下实现从“像素保真”到“语义保真”的转变；第二，打破“压缩 - 重建 - 处理”级联模式，构建跨模态统一 Token 空间与任务自适应传输策略，实现“压缩即服务”。项目将通过双流 Token 化架构解决时空冗余，并支持云端大模型直接消费压缩 Token 用于视觉问答、文生图等任务，在大幅降低带宽与计算开销的同时，确保下游任务性能不低于基线方法的 95%，推动智能编码与视觉理解的深度融合。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 标准提案：至少提交 2 项国际或国家标准提案，并被标准录用
5) 算法原型：研究图像与视频 Token 化智能编码算法，提升编码效率，同时保障语义保真度和下游任务准确度。在低于 0.02bpp 的码率下，LPIPS 指标优于 VTM-17.0 和 DCVC 系列方法。在低于 0.05bpp 的传输码率下，下游任务性能不低于基线方法（基于原始像素或高码率重建图像）的 95%
6) 技术指标：完成图像与视频 Token 化智能编码算法的设计，交付一套智能图像与视频 Token 化编解码算法原型，及其源代码

返回首页

10. 三维媒体感知与交互技术研究（备注：本课题支持金额不超过 50 万元）

研究背景

生成式人工智能正从“感知智能”迈向“空间智能”与“具身智能”，要求 AI 具备三维理解、物理推理和现实交互能力。在此趋势下，三维高斯泼溅（3DGS）技术凭借其在渲染速度、细节表达和训练效率上的显著优势，成为真实世界数字表示的主流手段，广泛应用于数字孪生、自动驾驶、机器人等领域。

然而，空间智能要求系统不仅“看见”，更要理解空间结构、物体关系和物理约束。当前 3DGS 在语义标注、动态建模和空间推理等方面仍有不足。为此，本项目旨在探索 3DGS 与多模态大模型、语义理解及物理约束的融合路径，推动三维世界从“可视化重建”向“可理解、可编辑、可交互、可行动”的智能空间表达演进。

研究目标是实现面向三维场景的可泛化、在线分割跟踪与编辑交互框架，使单目标分割小于 1 秒，且分割指标超越现有离线方案 SAGA。针对当前逐场景训练的离线方案缺乏实用性的问题，研究提出四步思路：

第一，解耦三维重建与分割。现有方法将重建与分割过程耦合，或需额外蒸馏时间，限制了动态与在线应用。本研究直接以已建好的 3DGS 场景为输入，实现在线三维高斯分割。

第二，实现亚秒级可泛化三维分割。为满足低延时和跨场景泛化需求，研究创新性地引入“虚拟无人机”（v-drone）机制，将三维分割任务转化为虚拟无人机的飞行规划及其视角下的二维跟踪任务，从而避免耗时的蒸馏学习，实现亚秒级可泛化目标分割。

第三，实现动态场景下的跟踪与分割。通过将 v-drone 扩展为“时空虚拟无人机”，使用时序无人机在时域跟踪，空间无人机逐帧分割，并结合卡尔曼滤波进行运动建模以提升稳定性。该框架为每个虚拟无人机配备二维基础模型并共享全局记忆力库，可统一处理动静态场景。

第四，基于分割与跟踪实现场景编辑与交互。可对动静态场景进行物体级在线编辑操作，如移除、复制、缩放等。通过进一步对齐世界坐标系、完善几何表示并添加物理属性，可支持虚拟现实交互、三维场景理解及为具身智能提供“仿真到现实”的训练框架。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 标准提案：至少提交 2 项国际或国家标准提案，并被标准录用
5) 算法原型：完成面向 3DGS 的三维感知与交互技术算法的设计，交付一套三维感知与交互原型，及其源代码
6) 技术指标：在线单目标分割时间 1 秒，分割指标（mIOU）超过离线分割算法 SAGA

返回首页

11. 面向研发风险前置防控的代码图谱增强技术与自进化多智能体框架技术研究-子课题一（基于代码仓库精准分析技术的变更风险左移系统研发与应用）

研究背景

AI Coding 与智能体辅助研发正在加快代码生成和变更速度，研发阶段的风险防控既需要判断代码及其变更是否存在缺陷，也需要识别这些缺陷可能影响的接口、消息、配置和业务链路。传统人工评审难以持续覆盖大规模变更，静态规则扫描对复杂业务语义和隐式依赖的识别有限，单一大模型分析则容易受到仓库上下文不完整、推理缺少证据和误报较多等问题制约，导致风险难以在代码提交、评审及发布准入前得到充分识别和有效阻断。本课题围绕“研发阶段代码异常提前识别与风险阻断”，研究代码图谱增强分析与自进化多智能体协同审计方法。以代码、配置、框架语义、历史变更和运行观测等多源证据为基础，贯通仓库上下文理解、变更影响分析、代码风险审计与反馈校正，形成能够说明风险位置、影响范围和判断依据的分析能力，为研发人员修复缺陷、补充验证以及执行风险拦截提供依据。

该研究主要支撑以下关键业务方向：

支撑“变更风险拦截和定位”。将代码缺陷识别和影响范围研判前置到研发流程，为代码评审、测试验证和发布准入提供风险及证据；同时依据影响范围支持精准监控配置和告警关联，并将历史告警、故障处置和专家确认结果用于改进研发阶段的风险判断。

支撑智能代码评审与研发质量左移相关目标。依托 AntCR 场景验证多角色协同、自进化和跨语言复用能力，减少无效风险提示与重复人工评审，提高研发阶段的风险发现效率，为 AI 生成代码和人工编写代码提供一致、可追溯的质量检查。

支撑“大促精细化变更管控”。在大促应用变更密集的情况下，识别是否影响大促链路以及受影响的 RPC/HTTP 接口、MSG、DRM 等关键对象，结合代码审计结果确定风险和验证重点，将专家介入集中到高风险或证据不足的变更，提高审批与发布效率，降低漏管控风险。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：交付支撑研发阶段代码风险识别与影响分析的算法原型。交付面向多语言软件系统的变更影响分析验证框架，包括关系发现与校验、变更上下文构建、图谱混合检索、影响传播与排序、置信度表达、证据路径生成和评测工具，并交付源代码、模型权重或其他 checkpoint、部署说明、接口文档及示例数据
5) 技术指标：在蚂蚁和/或其关联公司确认的脱敏真实仓库或等价公开数据集上完成评测。关系补全按关系类型报告准确率、召回率和 F1，目标隐式关系的准确率不低于 85%、召回率不低于 80%。变更上下文在保证关键影响召回的条件下，相对未裁剪图邻域的

节点数或上下文长度平均缩减不低于 50%

返回首页

12. 面向研发风险前置防控的代码图谱增强技术与自进化多智能体框架技术研究-子课题二（面向自进化的多角色智能体代码审计协作框架）

研究背景

AI Coding 与智能体辅助研发正在加快代码生成和变更速度，研发阶段的风险防控既需要判断代码及其变更是否存在缺陷，也需要识别这些缺陷可能影响的接口、消息、配置和业务链路。传统人工评审难以持续覆盖大规模变更，静态规则扫描对复杂业务语义和隐式依赖的识别有限，单一大模型分析则容易受到仓库上下文不完整、推理缺少证据和误报较多等问题制约，导致风险难以在代码提交、评审及发布准入前得到充分识别和有效阻断。 本课题围绕“研发阶段代码异常提前识别与风险阻断”，研究代码图谱增强分析与自进化多智能体协同审计方法。以代码、配置、框架语义、历史变更和运行观测等多源证据为基础，贯通仓库上下文理解、变更影响分析、代码风险审计与反馈校正，形成能够说明风险位置、影响范围和判断依据的分析能力，为研发人员修复缺陷、补充验证以及执行风险拦截提供依据。

该研究主要支撑以下关键业务方向：

支撑“变更风险拦截和定位”。将代码缺陷识别和影响范围研判前置到研发流程，为代码评审、测试验证和发布准入提供风险及证据；同时依据影响范围支持精准监控配置和告警关联，并将历史告警、故障处置和专家确认结果用于改进研发阶段的风险判断。

支撑智能代码评审与研发质量左移相关目标。依托 AntCR 场景验证多角色协同、自进化和跨语言复用能力，减少无效风险提示与重复人工评审，提高研发阶段的风险发现效率，为 AI 生成代码和人工编写代码提供一致、可追溯的质量检查。

支撑“大促精细化变更管控”。在大促应用变更密集的情况下，识别是否影响大促链路以及受影响的 RPC/HTTP 接口、MSG、DRM 等关键对象，结合代码审计结果确定风险和验证重点，将专家介入集中到高风险或证据不足的变更，提高审批与发布效率，降低漏管控风险。

预计产出

1) 报告：提交结项验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：交付支撑研发阶段代码风险识别与影响分析的算法原型。 完成 AI CR 适用的多角色协同智能体框架，并交付源代码
5) 技术指标：研究基于多角色智能体的代码审计方法，并形成自进化能力。在 AACR-Bench 等开源数据集上，相较于 OCR 等开源 AI CR 框架，准确率提升 10%、召回率提升 5%，并在蚂蚁和/或其关联公司 AI CR 场景落地

返回首页

超算与智算方向（支持金额不超过 30 万元/项）

1. 面向分布式训练、推理服务与 Agent 应用的低开销 Continuous Profiling 及其自进化机制研究

研究背景

随着大模型训练规模的持续扩大和 AI Agent 应用的快速增长，智算全链路的性能、资源效率和服务体验面临更高要求。训练侧，性能爬坡、评测周期长、规模扩展中的效率损失、运行时降速、异常难定位等问题，影响模型研发进度与算力产出，需要加快瓶颈定位和优化验证，提高训练吞吐与算力有效利用水平；在线推理与 Agent 应用侧，需要在业务增长下兼顾响应体验、服务容量与资源成本，而部分性能异常仅在特定请求、并发负载或运行状态下出现，离线测试难以还原其发生条件，增加了问题定位与优化验证的难度。提升持续性能剖析与诊断能力，有助于缩短优化和排障周期，支撑模型研发提效、业务体验改善、算力降本与服务稳定运行。

通智算全链路 Profiling 能力的关键，是在低运行开销下获取有效的性能数据，关联 Host 侧执行流程与设备执行，准确定位性能损失的环节与原因。然而，现有 Profiler 工具难以在生产任务中长期运行的同时，兼顾数据覆盖、Kernel 分析深度与较低的业务影响：低开销模式下的数据与上下文可能不足以解释复杂问题，部分性能数据难以准确关联到 Host 侧执行流程，影响端到端归因；异构设备的 Kernel 内部分析依赖平台专用能力和针对性开发，跨平台复用与持续改进成本较高。

预计产出

1) 报告：提交结题验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1-2 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：交付一套面向分布式训练、在线推理与 Agent 应用的低开销持续 Profiler 原型，提供源代码及验证框架。原型采集 CPU 调用栈、框架阶段耗时、Kernel 执行及通信事件，关联 Host 侧与设备执行流程，并提供跨平台 Kernel 可编程剖析接口，支持按问题指定剖析区域、采集内容和统计方式。当现有数据不足以定位问题时，自动生成或调整剖析方案，补充所需数据，验证数据准确性并评估运行开销与定位效果；在后续排查中复用经过验证的方案，并根据实际结果继续改进
5) 技术指标：在相同设备、输入和运行配置下，以未开启 Profiler 的同一任务为对照，持续剖析模式下训练与推理任务的 overhead（吞吐损失、执行耗时增幅） ＜1%，被剖析 Kernel 的执行时间增幅不超过 2%。面向慢节点与运行时性能退化、Host 侧阻塞、通信与同步等待、Kernel 内部执行瓶颈等典型问题，通过自动生成或改进剖析方案，实现问题定位成功率不低于 80%，人工介入率不超过 20%。交付跨平台 Kernel 可编程剖析原型，完成 GPU 适配，并完成 TPU、PPU、NPU 中至少一类平台的适配

返回首页

2. 面向 AI Agent 沙箱极速冷启动的 Nydus EROFS 按需加载与 Checkpoint/Restore 机制研究

研究背景

随着 AI 大模型与智能体技术进入规模化落地阶段，截至 2026 年 9 月，Agent 执行环境的启动速度、资源周转效率和服务稳定性被推向了新的高度。AI Agent 任务通常具有高并发、短生命周期、快速弹性扩缩容、环境依赖复杂等特点，沙箱作为 Agent 代码执行、工具调用和任务隔离的基础载体，其启动速度直接影响用户首次响应体验、任务调度效率和算力资源利用率。当前沙箱启动并不是单点问题，而是覆盖管控请求下发、沙箱调度、节点侧 containerd 创建、镜像准备、runD 运行时启动、OSS/存储挂载、网络设备初始化、日志初始化等多个环节的全链路问题。尤其在大镜像冷启动、无缓存节点扩容、批量任务拉起和高并发创建场景下，镜像完整下载与解压、运行时从零初始化、网络和存储资源串行准备、原生控制面链路过长、containerd 高并发 GC 抖动等问题会显著拉长启动时间，并造成创建长尾。提升 AI Agent 沙箱极速启动能力，有助于缩短业务等待时间、提高资源池周转效率、降低弹性扩容成本，并支撑大规模 Agent 服务稳定运行。

实现 AI Agent 沙箱极速启动的关键，是将传统“完整下载镜像、从零初始化运行时、串行准备资源”的启动路径，转变为“按需加载、状态复用、并行预热、轻量调度”的新启动范式。然而，现有容器和沙箱启动方案仍存在明显不足：传统 OCI 镜像通常需要完整拉取和解压，大镜像冷启动耗时高；runD 等安全运行时每次创建都需要重新准备运行环境、初始化资源并启动 guest 内核，重复开销明显；原生 K8s 控制面链路较长，难以满足 Agent 场景下毫秒级调度和快速拉起需求；网络、存储、containerd 等周边环节在高并发下容易出现内核锁争抢、RPC 排队、GC 风暴和创建长尾。更重要的是，镜像按需加载与沙箱运行时状态快照恢复往往分别设计，缺少面向 AI Agent 沙箱场景的统一数据格式、恢复链路和调度协同机制。基于此，本课题拟以 Nydus EROFS 格式的冷启动镜像 Lazyload 和 Nydus EROFS 格式的 Checkpoint/Restore 为核心，研究大镜像按需加载、沙箱状态固化与快速恢复、全链路协同优化机制，形成面向 AI Agent 沙箱的极速冷启动技术体系。

预计产出

1) 报告：提交结题验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1-2 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：交付一套面向 AI Agent 沙箱的极速冷启动原型系统，支持 Nydus EROFS 格式大镜像冷启动 Lazyload、Nydus EROFS 格式 Checkpoint/Restore、沙箱池化预热、网络/存储资源池化、控制面链路精简与运行时高并发优化
5) 技术指标：典型场景下目标实现：大镜像（以 4G 镜像为例）冷启动从 10s 左右降到 1s 左右，基于快照沙箱启动在 100ms 级，单机 100 个沙箱并发创建无明显长尾

返回首页

3. 面向大模型强化学习后训练的 GPU 动态资源重分配技术研究

研究背景

随着大语言模型能力持续提升，基于强化学习（Reinforcement Learning，RL）的后训练已成为提升大模型推理与复杂任务处理能力的重要技术路径。当前，大模型强化学习后训练通常采用 Rollout 与 Training 分离的计算架构，将样本生成和模型训练部署在不同 GPU 资源上，以充分发挥不同阶段的计算特征。

然而，Rollout 阶段受到模型生成长度、推理任务复杂度等因素影响，任务执行时间具有明显的动态性和长尾特征，而 Training 阶段则具有较为稳定的计算负载。传统系统通常采用静态 GPU 资源划分方式，难以根据不同阶段的运行状态动态调整资源。当 Rollout 和 Training 阶段执行时间不匹配时，容易产生流水线空泡和 GPU 资源空闲，降低整体训练吞吐率和昂贵 GPU 资源的利用效率。

在大模型规模不断扩大、强化学习后训练算力需求快速增长的背景下，如何在不改变强化学习训练语义和算法流程的前提下，根据 Rollout 和 Training 阶段的实时负载动态调整 GPU 资源，实现计算资源在不同阶段之间的低开销切换与高效利用，已成为大模型后训练系统亟待解决的重要问题。

研究方向包含但不限于大模型强化学习后训练的 Rollout/Training 分离执行与资源调度、GPU 资源运行时动态重分配、训练状态快速迁移与恢复、通信资源复用与低开销角色切换，以及面向负载波动的自适应资源伸缩与抖动抑制机制等。

预计产出

1) 报告：提交结题验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：1 套面向大模型强化学习后训练的 GPU 动态资源重分配原型系统，及其使用说明文档
5) 技术指标：相较典型静态 GPU 资源划分方案，端到端训练吞吐率提升不低于 20%，GPU 角色切换关键路径时延降低不低于 20%

返回首页

4. 面向大模型强化学习后训练的全局内存池化与高效数据传输技术研究

研究背景

随着大语言模型能力持续提升，强化学习后训练已成为进一步增强模型推理、规划和复杂任务处理能力的重要技术手段。当前大模型强化学习系统通常由 Rollout、Training 等多个执行阶段组成，不同阶段具有显著不同的计算和内存需求，并需要频繁交换模型权重、KV Cache、样本及中间状态等大规模数据。

随着模型规模和上下文长度不断增长，强化学习后训练对内存容量和数据传输能力提出了越来越高的要求。一方面，Rollout 阶段需要维护大量并发请求产生的 KV Cache，单个计算节点的高带宽内存容量逐渐成为系统扩展的重要限制；另一方面，Rollout 与 Training 之间需要周期性进行模型权重同步和运行状态交换，大规模数据搬运容易带来较高的通信开销，并进一步放大不同阶段之间的等待和流水线空泡。传统以单节点内存为中心、依赖跨节点网络进行数据交换的系统架构，难以同时满足大容量内存共享和高带宽数据传输需求。

新一代 AI 超节点通过高速 Scale-up 互联将大量加速器、CPU 及异构内存资源连接在统一互联域内，为强化学习后训练提供了构建全局内存资源池和高效数据交换的新机会。如何利用超节点的高速互联和全局可访问内存能力，将分散的 HBM 和 DRAM 资源进行统一管理，并针对 KV Cache、模型权重等不同类型数据提供高效传输能力，从而降低数据交换开销、缓解单节点内存容量瓶颈并提高强化学习后训练整体效率，已成为值得研究的重要系统问题。

研究方向包含但不限于超节点环境下的大模型强化学习内存资源池化、Rollout 阶段大规模 KV Cache 的统一管理与共享、Rollout 与 Training 之间的模型权重和状态高效传输、异构内存资源协同利用，以及面向强化学习工作负载的数据放置、传输调度与通信优化等。

预计产出

1) 报告：提交结题验收表，提交结项验收报告
2) 论文：投稿 CCF-A 类及蚂蚁认可的期刊/会议论文 1 篇并最终收录，提供论文底稿及收录邮件
3) 专利：乙方协助蚂蚁和/或其关联公司提交国内、国际专利至少 1 项，交付符合本项目创新点的专利申请号和专利申请相关材料
4) 算法原型：1 套面向大模型强化学习后训练的超节点全局内存池化与高效数据传输原型系统，及其使用说明文档
5) 技术指标：相较传统基于独立内存和常规数据传输方式的方案，端到端训练吞吐率提升不低于 20%

返回首页